

**SKRIPSI**

**PENERAPAN METODE CNN UNTUK KONVERSI ANGKA METERAN**

**ANALOG MENJADI DATA DIGITAL**

**(Untuk Menunjang Sistem Pencatatan Penggunaan Air PDAM)**

***THE APPLICATION OF CNN METHOD TO CONVERT ANALOG METER***

***NUMBERS INTO DIGITAL DATA***

***(To Support The Water Usage Recording System Of PDAM)***



**KHAERURRIJAL MAHDAR**

**200210502001**

**PROGRAM STUDI TEKNIK KOMPUTER**

**JURUSAN TEKNIK INFORMATIKA DAN KOMPUTER**

**FAKULTAS TEKNIK**

**UNIVERSITAS NEGERI MAKASSAR**

**2025**



KEMENTERIAN PENDIDIKAN DAN KEBUDAYAAN,  
RISET, DAN TEKNOLOGI  
UNIVERSITAS NEGERI MAKASSAR  
FAKULTAS TEKNIK  
**JURUSAN TEKNIK INFORMATIKA DAN KOMPUTER**

Alamat: JL. Daeng Tata Raya Parangtambung Makassar – 90224  
Telp. 0411-864935, Fax. 0411 – 861507, HP. 0853-1122-4040, Email: jtik@unm.ac.id | Laman tik.ft.unm.ac.id

**LEMBAR PENGESAHAN PROPOSAL**

Yang bertanda tangan di bawah ini, dengan ini menerangkan bahwa mahasiswa tersebut di bawah ini:


Nama : KHAERURRIJAL MAHDAR  
NIM : 200210502001  
Program Studi : Teknik Komputer - (S1)  
Jurusan : Teknik Informatika dan Komputer  
Judul : Penerapan Metode Cnn Untuk Konversi Angka Meteran Analog Menjadi Data Digital Untuk Menunjang Sistem Pencatatan Penggunaan Air PDAM

Setelah revisi laporan penelitian yang disusun oleh mahasiswa tersebut kami periksa, maka dinyatakan memenuhi syarat untuk melaksanakan **seminar proposal penelitian**.

Pembimbing I,

  
**Dr. Satria Gunawan Zain S.Pd., M.T.**  
NIP. 19800809 201012 1 002

Makassar, 6 Juni 2024  
Pembimbing II,

  
**Andi Baso Kaswar, S. Pd., M. Kom.**  
NIP. 19930215 201903 1 012

Mengetahui,

Ketua Jurusan  
Teknik Informatika dan Komputer  
  
  
**Dr. Ir. Mustari S. Lamada, S.Pd., M.T.**  
NIP. 19750505 200501 1 001

Ketua Program Studi  
Teknik Komputer  
  
**Dr. Satria Gunawan Zain, S.Pd., M.T.**  
NIP. 19800809 201012 1 002

## **KATA PENGANTAR**

Segala puji dan syukur penulis panjatkan kehadirat Allah Subhanahu Wa Ta'ala atas rahmat dan karunia-Nya yang tiada henti, sehingga penulis dapat menyelesaikan skripsi tugas terakhir yang berjudul “Penerapan Metode CNN untuk Konversi Angka Meteran Analog menjadi Data Digital untuk Menunjang Sistem Pencatatan Penggunaan Air PDAM”, sebagai suatu persyaratan melaksanakan siding kelulusan mahasiswa Universitas Negeri Makassar. Shalawat serta salam senantiasa penulis haturkan kepada Rasulullah Muhammad Shallallahu alaihi wasallam dan keluarganya, sebagai suri tauladan dan petunjuk kebenaran bagi umatnya.

Penulis sadar bahwa dalam penyusunan tugas akhir ini masih terdapat kekurangan dan keterbatasan dalam berbagai aspek. Oleh karena itu, penulis dengan tulus menerima segala kritikan dan saran dari pembaca demi menyempurnakan isi dan metode penulisan tugas akhir ini

Pada kesempatan ini, penulis ingin mengucapkan rasa terima kasih kepada semua pihak yang telah memberikan dukungan, semangat, dan doa tanpa henti, khususnya kepada kedua orang tua dan seluruh keluarga dan kepada semua pihak terkait yang telah membantu dalam terselesaikannya tugas akhir ini antara lain:

1. Orang tua penulis yakni Bapak Iskandar dan Ibu Sarinikmah yang selalu memberikan dukungan dan motivasi dengan penuh kasih sayang, serta doa terbaiknya sehingga penulis dapat menyelesaikan tugas skripsi ini tepat waktu.

2. Bapak Prof. Dr. Karta Jayadi, M.Sn.selaku Rektor Universitas Negeri Makassar.
3. Bapak Prof. Dr. H. Muhammad Yahya, M.Kes., M.Eng, selaku Dekan Fakultas Teknik Universitas Negeri Makassar.
4. Bapak Dr. Ir. Mustari S Lamada, S.Pd., M.T., selaku Ketua Jurusan Teknik Informatika dan Komputer.
5. Ibu Dr. Sanatang, M.T., selaku Sekretaris Jurusan Teknik Informatika dan Komputer.
6. Bapak Dr. Satria Gunawan Zain, S.Pd., M.T., selaku Ketua Program Studi Teknik Komputer.
7. Bapak Dr. Satria Gunawan Zain, S.Pd., M.T., selaku selaku Pembimbing I.
8. Bapak Andi Baso Kaswar, S. Pd., M. Kom., selaku pembimbing II.
9. Bapak Zulhajji, S.T., M.T., selaku Penguji I.
10. Ibu Fhatiah Adiba, S.Pd., M.Cs., selaku Penguji II.
11. Teman-teman mahasiswa TEKOM C 2020 dan konsentrasi Sistem Cerdas 2020.yang selalu kebersamai dan membantu dari awal perkuliahan sampai saat ini.

Makassar, 28 April 2025



KHAERURRIJAL MAHDAR

## DAFTAR ISI

<b>KATA PENGANTAR.....</b>	<b>iii</b>
<b>DAFTAR ISI.....</b>	<b>v</b>
<b>DAFTAR TABEL.....</b>	<b>v</b>
<b>DAFTAR GAMBAR.....</b>	<b>vi</b>
<b>BAB I PENDAHULUAN.....</b>	<b>1</b>
A. Latar Belakang .....	1
B. Rumusan Masalah .....	4
C. Tujuan Penelitian .....	4
D. Manfaat Penelitian .....	5
<b>BAB II TINJAUAN PUSTAKA.....</b>	<b>6</b>
A. Kajian Teori .....	6
B. Penelitian Relevan.....	16
C. Kerangka Pikir .....	18
<b>BAB III METODE PENELITIAN .....</b>	<b>19</b>
A. Jenis Penelitian.....	19
B. Waktu Dan Tempat Penelitian .....	19
C. Alat Dan Bahan.....	20
D. Prosedur Penelitian.....	20
E. Desain system.....	24
F. Teknik Pengujian .....	27
G. Teknik Analisis Data.....	30
<b>BAB IV HASIL DAN PEMBAHASAN.....</b>	<b>33</b>
A. Hasil penelitian.....	33
B. Pengujian sistem.....	36
<b>BAB Kesimpulan.....</b>	<b>56</b>
A. Kesimpulan .....	56
B. Saran.....	56
<b>DAFTAR PUSTAKA .....</b>	<b>58</b>

## DAFTAR TABEL

Tabel 3. 1.Skenario Pengujian Model .....	28
Tabel 3. 2 Pengujian Transformasi Citra.....	29
Tabel 3. 3 Skenario Fungsionalitas Website.....	29
Tabel 4. 1 perbandingan Model CNN .....	44
Tabel 4. 2 Skenario Fungsionalitas Website.....	52
Tabel 4. 3 Pengujian Transformasi.....	53
Tabel 4. 4 pengujian terhadap Pengaruh Cahaya.....	54

## DAFTAR GAMBAR

Gambar 2. 1 Meteran air analog.....	7
Gambar 2. 2 Arsitektur Convolutional Neural Network.....	10
Gambar 3. 1 prosedur penelitian.....	21
Gambar 3. 2 Arsitektur Sistem.....	22
Gambar 3. 3 Tampilan WEB Penggunaan Air PDAM .....	26
Gambar 3. 4 Tampilan Data penggunaan air PDAM.....	26
Gambar 3. 5 tampilan login untuk Karyawan .....	27
Gambar 3. 6 tampilan WEB penambahan data penggunaan air PDAM.....	27
Gambar 4. 1 Gambar Citra Meteran Air Analog .....	33
Gambar 4. 2 Augmentasi Citra.....	34
Gambar 4. 3 Proses Pelabelan Citra .....	35
Gambar 4. 4 Plot Accuracy MobileNet .....	37
Gambar 4. 5 Plot Accuracy EfficientNet.....	38
Gambar 4. 6 Plot Accuracy Resnet .....	39
Gambar 4. 7 Plot Accuracy VGGNet.....	40
Gambar 4. 8 Hasil Training Model YOLOv8n.....	41
Gambar 4. 9 hasil Training Model YOLOv8s.....	42
Gambar 4. 10 Grafik Hasil Perbandingan Akurasi Model.....	43
Gambar 4. 11 Grafik Perbandingan Model .....	43
Gambar 4. 12 Grafik Confusion Matrix Normalize.....	45
Gambar 4. 13 <i>Grafik Confusion Matrix</i> .....	46
Gambar 4. 14 Grafik Precision Recall Curve .....	47
Gambar 4. 15 Digram <i>Database</i> .....	49
Gambar 4. 16 Alur Penggunaan Flask.....	50
Gambar 4. 17 Tampilan website.....	52

# **BAB I**

## **PENDAHULUAN**

### **A. Latar Belakang**

Air merupakan zat yang sangat penting dalam kehidupan, baik sebagai kebutuhan pokok bagi makhluk hidup maupun dalam berbagai aktivitas manusia sehari-hari. Selain itu, air juga memiliki peran penting dalam peningkatan kesejahteraan masyarakat melalui pengairan pertanian, pembangkit listrik tenaga air, industri, dan berbagai keperluan lainnya (Lestari et al., 2021).

Dengan banyaknya manfaat yang dapat dihasilkan dari air bersih dan jumlahnya yang tersedia yang terbatas, mendorong pemerintah untuk mengembangkan suatu sistem pengelolaan penyediaan air bersih untuk masyarakat. Pengelolaan sumber daya air diatur dalam Undang-Undang Nomor 7 Tahun 2004 tentang Sumber Daya Air (UU SDA). Atas dasar undang-undang tersebut, Perusahaan Daerah air Minum (PDAM) berdiri sebagai salah satu bentuk pengelolaan sumber daya air dimana PDAM masih melakukan pengumpulan data konsumsi air pelanggannya dengan cara mengawasi langsung meter air pada saluran air di setiap rumah pelanggan secara bulanan dan mencatat penggunaan setiap meteran air.

Untuk mengetahui jumlah penggunaan air oleh masyarakat dan industri, PDAM menggunakan *flowmeter* atau biasa disebut meteran air. Alat ini dipasang di setiap rumah warga dan industri untuk mengetahui jumlah pemakaian air sehingga disetiap bulannya petugas PDAM akan melakukan



pencatatan jumlah air yang digunakan berdasarkan angka yang tertera pada *flowmeter* (Lauwis, 2017; Studi et al., 2022).

Data tersebut akan digunakan sebagai acuan jumlah biaya yang harus dibayarkan selama menggunakan air PDAM. Adapun sistem pencatatan penggunaan air dilakukan secara manual (Aini et al., 2023). Hal ini kurang akurat bagi PDAM sehingga mengakibatkan banyak masyarakat yang mengeluh dalam mengeluarkan jumlah biaya yang dibayarkan tidak sesuai dengan jumlah air yang digunakan. Kesalahan pencatatan oleh petugas PDAM biasa terjadi karena beberapa hal seperti *flowmeter* yang sudah tua sehingga tampilan angka tidak terlihat jelas, posisi dan pemasangan *flowmeter* yang terlalu dalam, *flowmeter* yang tertimbun tanah, atau *flowmeter* yang terendam air. Namun, untuk meningkatkan pelayanan kepada masyarakat terhadap kendala penghitungan manual PDAM mengeluarkan alat yang dilengkapi tombol untuk memasukkan data besaran penggunaan air. Alat ini biasa disebut *Handiy Terminal* (HT). Alat ini memiliki beberapa kelebihan, diantaranya data yang dimasukkan di lapangan dapat langsung dibaca oleh *server* sehingga memudahkan evaluasi pencatatan meteran, urutan data pencatatan dapat diatur oleh pencatat meter sendiri sehingga lebih mudah dikerjakan di lapangan (Hermawan, 2015). Meskipun memiliki banyak keunggulan dibandingkan pencatatan secara manual, pada kenyataannya masih saja ada pelanggan yang mengeluh ketidaksesuaian antara biaya yang dibayarkan dengan jumlah air yang digunakan. Hal ini disebabkan kesalahan dalam memasukkan data. Kesalahan tersebut bisa terjadi karena petugas harus menginputkan satu persatu data dalam satu wilayah.

Ar. Rivai Batara Ojja (2024) dalam penelitiannya “Pengembangan Sistem Data Center Data Capture Meteran Air Analog Berbasis ESP32CAM”, menyatakan bahwa ESP32CAM telah terbukti akurat dalam pengukuran konsumsi air dengan tingkat akurasi yang tinggi dan konsistensi, namun data yang didapatkan belum diproses untuk pencatatan penggunaan PDAM, data yang dihasilkan hanya digunakan untuk melihat perbandingan menggunakan ESP32CAM dengan tidak menggunakan ESP32CAM.

Penelitian terkait telah dilakukan oleh Adam Indra (2024), “Pengembangan Layanan Application Programming Interface Untuk Konversi Citra Meteran Air Analog Ke Teks Berbasis Web”. Dalam penelitiannya menyatakan bahwa menggunakan *dataset* yang didapatkan dari website *dataset /google* (Sekunder) dan menggunakan model CNN yolo5 pengembangan Application Programming Interface konversi citra meteran air analog ke teks mampu mendeteksi objek angka pada meteran air analog dan mengonversinya ke teks. Namun hasil dari deteksi angka yang didapatkan masih terdapat kesalahan pembacaan pada posisi angka yang terbalik.

Oleh karena itu, penulis mengangkat judul “Penerapan Metode CNN Untuk Konversi Angka Meteran Analog Menjadi Data Digital Untuk Menunjang Sistem Pencatatan Penggunaan Air PDAM” yang bertujuan untuk menunjang sistem pencatatan penggunaan air PDAM dengan menggunakan metode CNN seperti ResNet, DenseNet, MobileNet, EfficientNet, dan YOLOv8 yang dinilai mampu mendeteksi angka pada meteran air secara efektif dibandingkan model-model lainnya. Hasil pengujian dari model-model ini akan digunakan untuk memilih

model terbaik yang kemudian akan diimplementasikan ke dalam sebuah website, website ini akan menampilkan data penggunaan air pelanggan PDAM secara real-time.

## **B. Rumusan Masalah**

Berdasarkan latar belakang diatas, maka rumusan masalah dalam penelitian ini adalah sebagai berikut :

1. Bagaimana merancang dan membangun model Convolutional Neural Network (CNN) untuk mengenali dan mengkonversi angka pada meteran analog menjadi data digital dengan menggunakan YOLOv8 ?
2. Bagaimana hasil pengujian model Convolutional Neural Network (CNN) dalam mengonversi angka pada meteran analog menjadi data digital?
3. Bagaimana hasil pengujian model yang telah diimplementasikan ke dalam website?

## **C. Tujuan Penelitian**

Berdasarkan permasalahan di atas, tujuan dilakukannya penelitian ini adalah sebagai berikut:

1. Untuk mengetahui hasil perancangan model Convolutional Neural Network (CNN) dan YOLOv8 yang mampu mengenali dan mengonversi angka pada meteran analog menjadi data digital.
2. Untuk mengetahui hasil akurasi pengujian model CNN dalam melakukan konversi angka meteran analog menjadi data digital dengan membandingkan hasilnya terhadap metode konversi manual.

3. Untuk mengetahui hasil tampilan yang menunjukkan hasil data digital kedalam sebuah website.

#### **D. Manfaat Penelitian**

Adapun manfaat penelitian sebagai berikut :

1. Meningkatkan akurasi dan efisiensi pencatatan melalui penerapan model Convolutional Neural Network (CNN) yang dapat secara signifikan mengurangi kesalahan manusia dalam pembacaan angka pada meteran analog. Sistem otomatis ini juga mempercepat proses pencatatan, memungkinkan pengumpulan data secara efisien dan membantu mengoptimalkan tugas pegawai lapangan PDAM dalam pendataan penggunaan air.
2. Pengimplementasian model CNN yang telah dibuat ke dalam website untuk memudahkan pengguna dalam mengakses dan menggunakan sistem konversi angka secara real-time.

## **BAB II**

### **TINJAUAN PUSTAKA**

#### **A. Kajian Teori**

##### **1. Perusahaan Daerah Air Minum (PDAM)**

Perusahaan Daerah Air Minum (PDAM) merupakan salah satu fasilitas pelayanan penyedia air minum yang memiliki peran yang sangat penting di mana Perusahaan Daerah Air Minum (PDAM) adalah Badan Usaha Milik Daerah (BUMD) yang bergerak dalam bidang pelayanan air minum bagi masyarakat umum yang diawasi oleh aparat-aparat eksekutif maupun legislatif (Pramono et al., 2022). PDAM terdapat di setiap provinsi, kabupaten, dan kotamadya di seluruh Indonesia (Parawangi et al., 2021).

Sebagai Badan Usaha milik daerah (BUMD) PDAM mengatur penggunaan air dengan melalui pencatatan angka penggunaan pada meteran air analog . Meteran analog adalah perangkat yang digunakan untuk mengukur penggunaan air secara mekanis. (*water meter*: definisi, fungsi, jenis dan spesifikasinya, 2024). Meteran air analog umumnya menggunakan roda pengukur atau jarum untuk menunjukkan jumlah penggunaan air, yang memudahkan dalam menentukan biaya penggunaan air. PDAM melakukan pencatatan penggunaan air pada setiap meteran analog, baik untuk pelanggan rumah tangga maupun industri.

Cara kerja meteran air analog melibatkan aliran air yang melewati meteran ketika digunakan oleh konsumen. Aliran air ini menggerakkan turbin atau roda gigi di dalam meteran, yang kemudian mengubah aliran air menjadi gerakan mekanis.

Gerakan mekanis dari turbin atau roda gigi ini menggerakkan jarum atau rol pada dial meteran, sehingga jumlah penggunaan air dapat terbaca pada skala atau dial tersebut. Petugas PDAM atau konsumen dapat membaca angka yang tertera untuk mengetahui jumlah air yang telah digunakan. Konsumen atau petugas PDAM dapat membaca angka ini untuk mengetahui konsumsi air seperti pada gambar di bawah.



Gambar 2.1 Meteran air analog

Teknologi pengenalan citra dan machine learning dapat digunakan untuk membaca meteran air analog secara otomatis. Dengan menggunakan model CNN (Convolutional Neural Network), pembacaan meteran analog dapat dikonversi menjadi data digital. Proses ini melibatkan pengambilan gambar meteran air menggunakan kamera, pengenalan pola oleh algoritma untuk mengenali dan mencatat angka yang ditunjukkan oleh jarum atau rol pada meteran, dan konversi angka yang terdeteksi menjadi data digital yang dapat digunakan untuk analisis dan penagihan.

Penggunaan teknologi ini membawa banyak manfaat seperti peningkatan akurasi dengan mengurangi kesalahan pembacaan manual, efisiensi yang lebih

tinggi dalam proses pengumpulan data, dan otomatisasi yang memungkinkan pemantauan penggunaan air secara real-time. Ini membuat proses penagihan dan pengelolaan data konsumsi air menjadi lebih mudah dan cepat.

## **2. Machine Learning**

Seiring dengan perkembangan teknologi kecerdasan buatan, Machine Learning (ML) telah menjadi salah satu bidang utama yang mendapat perhatian besar dalam penelitian dan pengembangan. Machine Learning (ML) adalah cabang Kecerdasan Buatan (AI) yang mampu belajar seperti manusia. AI terbagi menjadi tujuh cabang: Machine Learning, Natural Language Processing, Expert Systems, Vision, Speech, Planning, dan Robotics. ML berfokus pada algoritma dan model komputer yang belajar dari data untuk membuat prediksi atau keputusan, meniru cara manusia dan hewan belajar melalui pengalaman (Minarno et al., 2022).

Machine Learning memiliki beberapa pendekatan atau jenis utama, termasuk:

### **a. Supervised Learning:**

Algoritma belajar dari data yang telah dilabeli sebelumnya untuk membuat prediksi atau mengambil keputusan pada data baru. Contohnya adalah klasifikasi (memisahkan data menjadi kategori) dan regresi (memprediksi nilai berkelanjutan).

### **b. Unsupervised Learning**

Algoritma belajar dari data yang tidak dilabeli dan mencoba untuk menemukan pola atau struktur yang bermanfaat dalam data tersebut. Contohnya adalah pengelompokan (klasterisasi) dan reduksi dimensi (mengurangi kompleksitas data).

### **c. Reinforcement Learning**

Algoritma belajar melalui interaksi dengan lingkungan, dengan mencoba tindakan berbeda dan memperoleh umpan balik positif atau negatif sebagai hasil dari tindakan tersebut. Tujuan utamanya adalah untuk memaksimalkan hadiah atau hasil yang diinginkan.


### **3. Convolutional Neural Network (CNN)**

CNN adalah jenis jaringan saraf tiruan feedforward yang digunakan khususnya untuk memproses data berstruktur seperti gambar. Pada arsitektur CNN, setiap neuron terhubung dengan area kecil dari layer sebelumnya, meniru cara kerja visual cortex manusia. Ini memungkinkan CNN untuk efektif mengenali pola dalam data spasial seperti gambar. CNN terdiri dari beberapa jenis layer, termasuk convolutional layer yang menggunakan filter untuk mengekstrak fitur-fitur penting dari gambar, serta pooling layer yang mengurangi dimensi spasial dari fitur-fitur yang diekstrak. Arsitektur CNN dapat divariasikan dengan mengubah jenis dan jumlah layer, memungkinkan adaptasi untuk berbagai tugas pengolahan gambar seperti klasifikasi dan deteksi objek.(Giri, 2021)

Convolutional Neural Network (CNN) adalah salah satu metode yang berkembang pesat dalam supervised learning, terutama dalam pemrosesan data yang terstruktur seperti gambar. Keunggulan utama CNN terletak pada kemampuan yang luar biasa dari jaringan saraf tersebut. Performa menjadi fokus utama dalam pengembangan CNN, di mana setiap lapisan dirancang untuk mengekstrak fitur-fitur penting dengan efektif dari data input, seperti pola visual



pada gambar. Dengan kemampuan ini, CNN mampu memberikan hasil yang sangat baik dalam berbagai tugas seperti klasifikasi gambar, deteksi objek, dan segmentasi gambar. (Rahmawan et al., 2023).



Gambar 2. 2 Arsitektur Convolutional Neural Network

Sumber : (<https://shorturl.at/BY3OV>)

Arsitektur Convolutional Neural Network (CNN), seperti yang ditunjukkan pada Gambar 2.3, terdiri dari dua tahap utama: pembelajaran fitur dan klasifikasi. Pada tahap ekstraksi fitur, CNN menggunakan beberapa hidden layer yang mencakup convolution layer untuk mencari fitur dengan menggunakan filter, serta pooling layer yang berfungsi untuk mengurangi dimensi fitur tanpa kehilangan informasi penting. Selanjutnya, dalam tahap klasifikasi, proses dimulai dengan flatten layer, yang mengubah representasi matriks multidimensional dari hasil operasi konvolusi dan pooling menjadi vektor satu dimensi. Vektor hasil flatten ini kemudian diteruskan ke fully connected layer, yang bertujuan mentransformasikan data ke dalam dimensi yang sesuai untuk klasifikasi. Di akhir proses, fungsi aktivasi softmax digunakan untuk mengubah nilai-nilai neuron output menjadi distribusi probabilitas yang jumlahnya sama dengan satu. Fungsi softmax ini sangat

berguna untuk menginterpretasikan output sebagai probabilitas dari berbagai kelas (Dan & Luas, 2020).

Convolution Neural Network (CNN) terdiri dari beberapa arsitektur seperti, ResNet, DenseNet, MobileNet, EfficientNet, dan juga YOLOv8 yaitu :

#### **a. Residual Neural Network (ResNet)**

Diperkenalkan oleh Kaiming He dan timnya, merupakan arsitektur deep learning yang populer karena kemampuannya mengatasi masalah *vanishing gradient* pada model CNN yang sangat dalam. Masalah ini terjadi ketika gradien yang diperlukan untuk pembaruan bobot tereduksi seiring bertambahnya kedalaman, membuat lapisan awal gagal belajar dari kesalahan. Untuk mengatasi hal ini, ResNet menggunakan residual block yang memungkinkan gradien mengalir lebih baik melalui shortcut atau skip connection, sehingga menjaga model tetap efektif bahkan dengan jumlah lapisan yang besar. Inovasi ini membuat ResNet unggul dalam berbagai tugas seperti klasifikasi gambar, deteksi objek, dan segmentasi gambar. DenseNet adalah arsitektur yang memperkenalkan konsep koneksi padat antar lapisan, di mana setiap lapisan menerima input dari semua lapisan sebelumnya. Ini membantu dalam mengatasi masalah gradien yang menghilang dan juga meminimalkan jumlah parameter karena tidak perlu setiap lapisan memiliki filter yang banyak (Riyadi et al., 2022).

#### **b. MobileNet**

Arsitektur CNN yang dirancang oleh Google untuk perangkat mobile dan embedded systems. Arsitektur ini sangat efisien karena menggunakan "depthwise

separable convolutions," yang secara signifikan mengurangi jumlah parameter dan operasi komputasi tanpa mengorbankan akurasi secara berlebihan.

#### **c. EfficientNet**

Arsitektur CNN yang dirancang dengan memperhatikan trade-off antara akurasi dan efisiensi komputasi. Model ini menggabungkan skala jaringan dalam tiga dimensi: kedalaman, lebar, dan resolusi gambar input, dan secara empiris menentukan skala optimal menggunakan teknik yang disebut "compound scaling."

#### **d. YOLOv8**

Versi terbaru dari keluarga YOLO, yang merupakan arsitektur untuk deteksi objek waktu nyata. YOLO diperkenalkan oleh Joseph Redmon pada tahun 2016, dan sejak itu telah mengalami banyak iterasi untuk meningkatkan kecepatan dan akurasi. YOLOv8 memperkenalkan berbagai peningkatan dalam hal efisiensi komputasi, akurasi, dan kemampuan deteksi objek yang lebih kecil dan lebih halus.

YOLOv8 tetap setia pada prinsip inti YOLO, di mana seluruh proses deteksi objek dilakukan dalam satu lintasan jaringan, menjadikannya sangat cepat. Versi terbaru ini sering digunakan dalam aplikasi yang memerlukan deteksi objek waktu nyata seperti sistem pengawasan, drone, dan aplikasi kendaraan otonom.

### **4. YOLO (You Only Look Once)**

You only look once atau sering disebut dengan yolo artinya mendeteksi multi objek dalam 1 citra, dan dapat digunakan untuk mendeteksi objek secara real time. Algoritma YOLO diperkenalkan oleh Joseph Redmon pada tahun 2015 dan masih populer hingga saat ini karena memiliki tingkat akurasi yang tinggi serta dapat dijalankan secara real-time.

Algoritma YOLO merupakan bagian dari Convolutional Neural Network (CNN) yang sering diaplikasikan dalam klasifikasi objek melalui citra gambar. Sistem pendekatan algoritma ini yaitu dengan menerapkan jaringan saraf tunggal pada keseluruhan gambar. Jaringan ini melakukan klasifikasi dan prediksi pada kotak pembatas untuk dilakukan penentuan tingkat probabilitas kecocokan dari objek yang dideteksi.

Konsep kerja YOLO yakni dengan membagi gambar ke dalam bentuk grid kotak berukuran  $S \times S$ . Jika pusat suatu objek berada dalam suatu grid, maka grid tersebut bertugas untuk mendeteksi objek tersebut. Setiap grid memproyeksikan  $B$  bounding boxes dan confidence score yang menunjukkan probabilitas keberadaan objek dalam kotak tersebut, serta seberapa akurat kotak tersebut diprediksi. Jika tidak terdapat objek yang terdeteksi maka nilai dari confidence score tetap nol. Tiap bounding box memiliki atribut yang dibagi menjadi tiga kelompok besar, yaitu coordinate, objectness score dan class score (Deteksi et al., 2024).

Arsitektur YOLO versi 5 terdiri dari 3 bagian yaitu backbone, neck, head dimana terdapat proses konvolusi dari setiap bagiannya.

## **5. Optical Character Recognition (OCR)**

Optical Character Recognition (OCR) adalah teknologi yang digunakan untuk mengenali dan mengonversi teks yang ada dalam gambar atau dokumen grafis menjadi teks digital yang dapat diolah oleh komputer. Teknologi ini memungkinkan pembacaan angka pada meteran air secara otomatis, di mana OCR mengenali dan mengonversi angka-angka tersebut menjadi data digital yang siap untuk dianalisis.

Tesseract adalah perangkat lunak OCR open-source yang awalnya dikembangkan oleh Hewlett-Packard (HP) antara tahun 1984 dan 1994. Pada tahun 1995, perangkat lunak ini dimodifikasi untuk meningkatkan akurasi, dan pada tahun 2005, HP merilisnya sebagai open-source. Setelah itu, pengembangan Tesseract dilanjutkan oleh Google. Tesseract memproses teks dengan mengubah gambar menjadi biner, kemudian menganalisis tepi setiap karakter untuk mengenali teks. Dalam penelitian ini, Tesseract digunakan untuk memproses gambar meteran air yang diambil oleh ESP32-CAM, di mana hasil pemrosesan ini disimpan dan ditampilkan di halaman web .

## 6. Computer Vision

Computer Vision (CV) merupakan cabang ilmu kecerdasan buatan yang memungkinkan komputer untuk melihat, memahami, dan menginterpretasi dunia visual seperti manusia. CV menggunakan teknik-teknik pemrosesan gambar digital, analisis statistik, dan pembelajaran mesin untuk memahami dan menganalisis visual dari dunia nyata (Rachmaniar et al., 2022). Berikut adalah beberapa konsep utama dalam Computer Vision:

- a. **Pengolahan Citra** : Melibatkan teknik-teknik seperti filtering, enhancement, dan segmentasi untuk memanipulasi gambar digital dan mengekstrak fitur-fitur penting.
- b. **Deteksi dan Pengenalan Objek** : Memungkinkan komputer untuk mendeteksi objek dan mengenali jenis objek tertentu dalam gambar atau video.
- c. **Segmentasi Objek** : Memisahkan objek dari latar belakang, memungkinkan analisis yang lebih baik terhadap objek tersebut.

- d. **Rekonstruksi 3D** : Membuat model tiga dimensi dari objek atau lingkungan berdasarkan informasi visual yang diterima.
- e. **Pengenalan Pola** : Mengidentifikasi pola yang penting dalam gambar, seperti pengenalan wajah, karakter tulisan tangan, atau objek lainnya.
- f. **Analisis Gerakan** : Melacak gerakan objek dari frame ke frame dalam urutan gambar atau video.
- g. **Pengolahan Video** : Analisis dan pengolahan video untuk mendeteksi peristiwa atau perilaku tertentu.
- h. **Augmented Reality (AR)** : Menggabungkan elemen digital ke dalam pandangan dunia nyata, sering digunakan dalam aplikasi permainan atau panduan visual.
- i. **Pengenalan Teks** : Mendeteksi dan mengenali teks dalam gambar atau video.

Computer Vision memiliki aplikasi yang luas dalam berbagai bidang, termasuk pengawasan keamanan, mobil otonom, pengenalan pola, pengolahan medis, dan banyak lagi. Dengan kemajuan dalam teknologi jaringan saraf tiruan dan komputasi grafis, Computer Vision terus berkembang dan memberikan kontribusi besar dalam mendorong inovasi teknologi.

## **7. Pengolahan Citra Digital**

Citra memiliki peran penting dalam multimedia karena mampu menginterpretasikan data secara visual dengan kaya dan mendalam. Ungkapan "satu gambar bernilai lebih dari seribu kata" mencerminkan kekuatan citra dalam menyampaikan pesan secara efektif, termasuk nuansa, emosi, dan konteks yang sulit diungkapkan dengan kata-kata. Pengolahan citra merupakan bidang

multidisiplin yang melibatkan fisika, elektronika, matematika, seni, fotografi, dan teknologi komputer, dengan tujuan mengubah input citra menjadi output citra (Lubis, 2021).

Secara teknis, sebuah citra adalah representasi visual dalam ruang dua dimensi, yang dalam konteks matematis adalah fungsi kontinu dari intensitas cahaya dalam ruang dua dimensi. Proses pembuatan citra dimulai dengan sumber cahaya yang memancarkan sinarnya, yang kemudian mengenai objek dan dipantulkan kembali. Sinar yang dipantulkan oleh objek tersebut kemudian direkam oleh alat-alat optik seperti mata, kamera, scanner, dan sebagainya, sehingga menciptakan bayangan objek yang kita lihat sebagai citra.

## **8. Pengenalan Pola**

Pengenalan pola adalah cabang dari kecerdasan buatan (AI) dan pengolahan citra digital yang bertujuan untuk mengidentifikasi dan memahami struktur serta pola dalam data. Dalam konteks pembacaan meteran air analog PDAM, pengenalan pola digunakan untuk secara otomatis membaca angka yang ditunjukkan oleh jarum atau rol pada dial meteran. Teknologi ini memungkinkan pengumpulan data yang lebih akurat dan efisien, serta mengurangi kebutuhan untuk pembacaan manual.

## **B. Penelitian Relevan**

Berikut beberapa penelitian terdahulu yang relevan dengan penelitian yang dilakukan oleh peneliti :

1. Pada penelitian oleh AR.RIVAI BATARA OJJA yang berjudul “Pengembangan Sistem Data Center Data Capture Meteran Air Analog

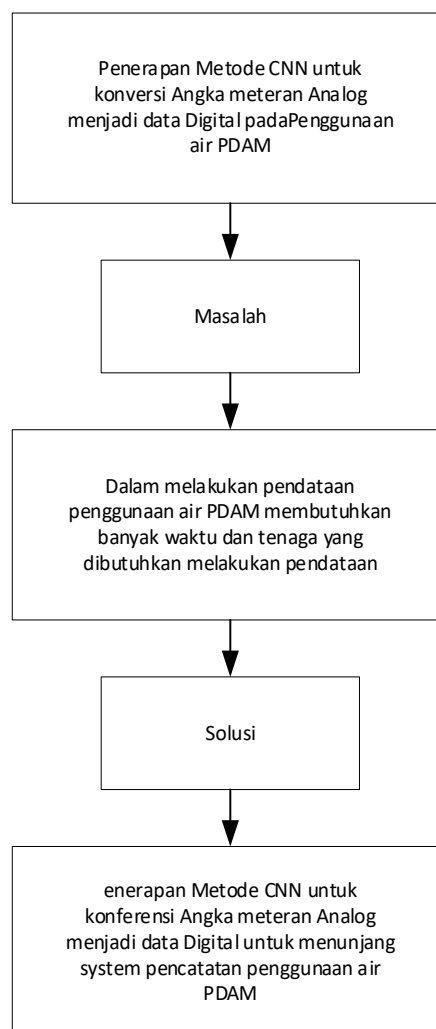
Berbasis ESP32CAM” (OJJA, 2024). Namun pada penelitian ini data yang didapatkan belum diproses untuk pencatatan penggunaan PDAM, data yang dihasilkan hanya digunakan untuk melihat perbandingan menggunakan ESP32CAM dengan tidak menggunakan ESP32CAM.

2. Pada penelitian oleh wiwin Windihastuty, Retno Wulandari dan Mulyati (Windihastuty, 2023) yang berjudul “Deteksi Angka Meter Air Dengan Membandingkan Algoritma Backpropagation Dan Single Perception”. Pada penelitian ini menggunakan metode jaringan saraf tiruan backpropagation, penelitian ini memperoleh tingkat akurasi terbaik mencapai 92% setelah 15 kali pelatihan menggunakan ukuran citra 25x25 piksel. Namun pada penelitian ini tingkat kecocokan yang hanya mencapai 60% dari 15 citra uji, sehingga dibutuhkan lebih banyak eksperimen untuk meningkatkan keandalan sistem.
3. Pada penelitian oleh NURUL AZIZAH yang berjudul “METODE PENGUMPULAN DATA DEBIT AIR PADA SALURAN DISTRIBUSI AIR PDAM MAKASSAR BERBASIS IOT” (AZIZAH, 2024). Yang dimana penelitian ini menunjukkan akurasi tinggi (98%) dalam pencatatan debit air, namun terdapat kekurangan seperti sedikit perbedaan hasil akibat kualitas gambar atau pencahayaan. Selain itu, sistem sangat bergantung pada stabilitas koneksi WiFi, yang dapat mengganggu pengiriman data saat jaringan tidak stabil.
4. Pada penelitian oleh ADAM INDRA KAPARANG dengan judul “Pengembangan Layanan Application Programming Interface Konversi Citra Meteran Air Analog Ke Teks Berbasis Web”(KAPARANG, 2024) di mana pada penelitian tersebut menggunakan *dataset* yang didapatkan dari website



dataset dari google (Sekunder) dan menggunakan model CNN yolo5 dengan nilai metrik dengan precision sebesar 0.943 atau 94.3%, recall sebesar 0.881 atau 88.1%, mAP50 sebesar 0.944 atau 94.4%, dan mAP50-95% sebesar 0.599 atau 59.9%.

### C. Kerangka Pikir



Gambar 2.1 Kerangka Pikir

## **BAB III**

### **METODE PENELITIAN**

#### **A. Jenis Penelitian**

Penelitian yang digunakan dalam penelitian ini adalah Research and Development (R&D). Menurut Sugiyono (2013), metode R&D adalah metode penelitian yang bertujuan untuk menghasilkan produk tertentu dan menguji efektivitas produk tersebut. R&D menghasilkan inovasi berupa produk baru atau mengembangkan produk yang sudah ada untuk mencapai tujuan spesifik.

Penelitian ini bersifat R&D karena melibatkan inovasi dan pengembangan produk, serta peningkatan pengetahuan dalam deteksi angka pada meteran air menggunakan Convolutional Neural Network (CNN). CNN, sebagai jenis jaringan saraf tiruan yang efektif untuk pengolahan gambar, memiliki beberapa lapisan penting: lapisan konvolusi untuk mendeteksi fitur, lapisan ReLU untuk menambah non-linearitas, lapisan pooling untuk mereduksi dimensi data, lapisan fully connected untuk menggabungkan fitur, dan lapisan output untuk klasifikasi. Dengan mendeteksi fitur dari dasar hingga kompleks secara bertahap, CNN menjadi sangat ideal untuk tugas pengenalan dan klasifikasi gambar.

#### **B. Waktu Dan Tempat Penelitian**

Penelitian ini berlangsung selama dua bulan, dari November hingga Desember 2024, di Laboratorium Sistem Cerdas dan Laboratorium Embedded System, Program Studi Teknik Informatika dan Komputer, Fakultas Teknik, Universitas Negeri Makassar.

### **C. Alat Dan Bahan**

Alat dan bahan yang digunakan pada penelitian ini sebagai berikut :

#### **1. Perangkat keras (Hardware)**

Adapun Perangkat keras yang di gunakan adalah sebagai berikut :

##### **a. PC , dengan spesifikasi :**

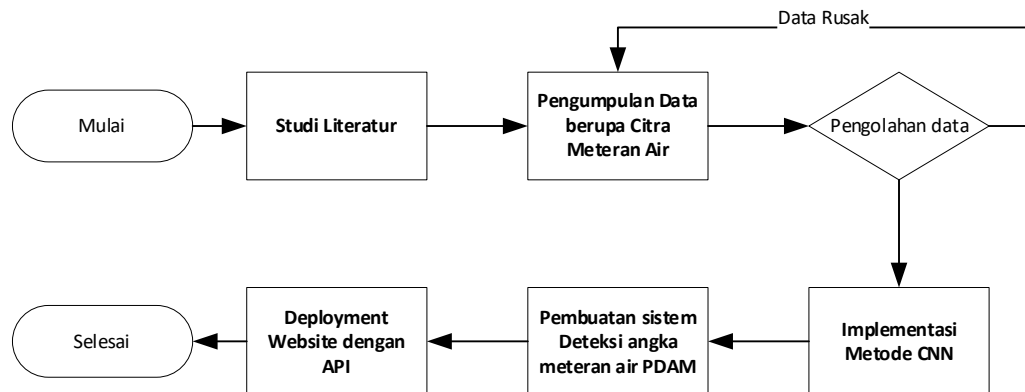
- Processor Intel(R) Core(TM) i7-6700HQ CPU @ 2.60GHz 2.59 GHz
- RAM 16 GB
- Graphics Card GPU NVIDIA GeForce GTX 950M, 9,9GB
- SSD 512 GB

##### **b. Perangkat Lunak (Software)**

- a. Sistem Operasi Windows 11 64 Bit
- b. Visual Studio Code
- c. Web Browser
- d. XAMPP
- e. Bahasa pemrograman JavaScript dan Python min v3.8
- f. Library Pytorch

### **D. Prosedur Penelitian**

Prosedur penelitian meliputi identifikasi masalah, kajian pustaka, perumusan hipotesis atau tujuan, desain penelitian, pengumpulan dan analisis data, interpretasi hasil, kesimpulan dan rekomendasi, serta penyusunan laporan. Langkah-langkah ini memastikan penelitian berjalan sesuai tujuan.



*Gambar 3. 1 prosedur penelitian*

Langkah-langkah dalam penelitian tersebut adalah sebagai berikut:

### 1. Studi Literatur

Tahap pertama dalam memulai penelitian ini adalah mencari literatur dari berbagai sumber seperti buku, jurnal, dan internet. Tujuannya adalah memahami kelebihan dan kekurangan sistem yang telah dikembangkan sebelumnya, prinsip kerjanya, serta teori-teori yang mendukung. Dengan demikian, diharapkan literatur yang diperoleh dapat memberikan masukan yang berguna dan membantu mengurangi potensi kesalahan selama penelitian. Di mana Tarif air untuk rumah tangga di PDAM Makassar pada tahun 2024 adalah sekitar IDR 6.825 per meter kubik ( $m^3$ ) untuk konsumsi rendah. Tarif ini bisa lebih tinggi untuk penggunaan yang lebih banyak atau untuk pelanggan komersial.

### 2. Pengumpulan Data

Pada tahap ini data yang dikumpulkan didapatkan dari hasil captur EPS32-CAM dari penelitian AR.RIVAI BATARA OJJA dan juga melakukan pengambilan gambar langsung (Data set Primer) menggunakan hp untuk menemukan hasil gambar yang jelas. Data ini akan digunakan sebagai sampel dalam pengujian

deteksi angka pada meteran air analog. Pengambilan data dilakukan pada waktu yang berbeda untuk mendapatkan hasil gambar yang bagus.

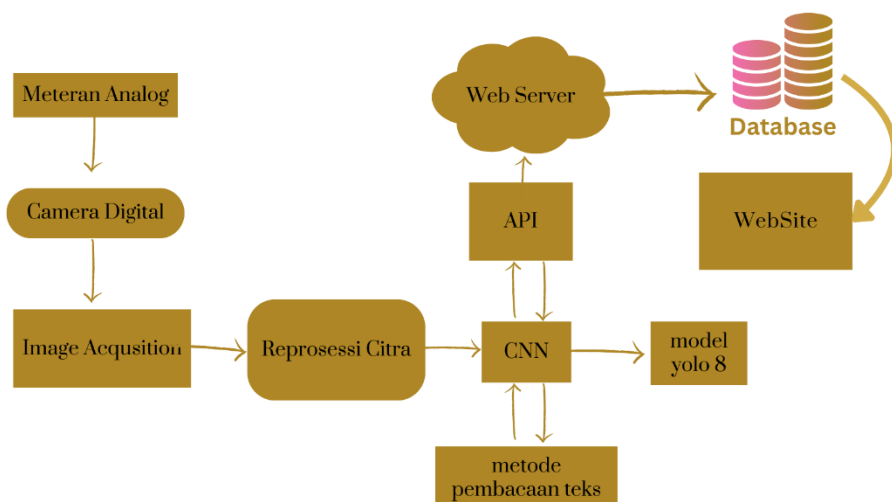
### 3. Pengolahan data

Pada tahap ini data diolah dengan melalui 2 tahapan yaitu

- a. Pembagian data Setelah mengumpulkan data kemudian data dibagi menjadi 2 yaitu data latih dan data uji dengan 80% data training dan 20% data ujim
- b. Pelabelan. Setelah melakukan pembagian *dataset* kemudian dilakukan pelabelan untuk menentukan angka pada meteran air analog menjadi data digital. pelabelan dilakukan menggunakan Roboflow.

### 4. Implementasi Metode CNN

Arsitektur sistem akan menampilkan gambaran umum keseluruhan dari alur sistem yang akan dibangun nantinya. Arsitektur sistem yang akan dibangun dapat dilihat pada gambar 3.2.



Gambar 3. 2 Arsitektur Sistem

proses konversi angka pada meteran analog menjadi data digital menggunakan Integrasi Convolutional Neural Network (CNN) dan YOLOv8 ke dalam sistem berbasis web dimulai dengan pengambilan gambar meteran analog menggunakan kamera digital. Tahap awal, Image Acquisition, menghasilkan citra siap olah, yang kemudian ditingkatkan kualitasnya melalui Preprocessing agar optimal untuk pemrosesan CNN. CNN berfungsi mengenali angka pada meteran dengan mengekstraksi fitur-fitur penting dalam gambar, sementara metode Optical Character Recognition (OCR) mengonversi angka yang dikenali menjadi teks digital. YOLOv8 mendukung deteksi objek cepat dan akurat, terutama dalam pengenalan angka pada meteran. API kemudian menghubungkan sistem ke web server untuk menyimpan hasil pengenalan angka ke dalam database, yang dapat diakses melalui website. Sistem ini meningkatkan akurasi dan efisiensi pencatatan penggunaan air, menggantikan metode manual yang lambat dan rawan kesalahan, sekaligus memudahkan petugas PDAM dalam pengelolaan data.

## **5. Uji coba Model**

Pada tahap ini dilakukan pengujian model model CNN seperti, Resnet, DenseNet MobileNet, EfficientNet, dan YOLOv8 (You Only Look Once) untuk mendapatkan hasil akurasi yang baik. Di mana setiap model mendapatkan Hasil yang dicapai mencakup metrik seperti Precision, mAP50, dan mAP50%-95%. Model terbaik yang digunakan untuk mendeteksi gambar meteran air. Model ini juga dapat digunakan kembali untuk pelatihan lebih lanjut dengan *dataset* yang berbeda.

## **6. Studi perbandingan**

Setelah melakukan implementasi model CNN kemudian melakukan studi perbandingan untuk menentukan model yang cocok digunakan untuk mendeteksi angka meteran analog menjadi digital di mana hasil yang didapatkan mampu mendeteksi angka secara akurat dan juga mendapatkan hasil akurasi yang tinggi.

## **7. Implementasi model CNN kedalam website**

Setelah melakukan uji coba model kemudian model disimpan dalam file `best.pt`, yang digunakan untuk mendeteksi gambar meteran air. Dan kemudian dalam Implementasi model CNN kedalam website memerlukan tahapan sebagai berikut :

### **a. Membuat API untuk Model**

API memungkinkan model Anda untuk diakses oleh website. Dengan menggunakan framework seperti Flask, Anda dapat membuat endpoint yang menerima data gambar dari website, memprosesnya, dan mengembalikan hasil prediksi.

### **b. Integrasi dengan Website**

Integrasikan API dengan website Anda menggunakan JavaScript untuk mengirim data gambar dan menerima hasil prediksi. Anda bisa menggunakan `fetch` API untuk melakukan permintaan POST ke server.

## **E. Desain system**

Setelah melewati tahap-tahapan `praprocessing` data, tahap selanjutnya dalam prosedur penelitian ini adalah merancang system yang digunakan untuk menyelesaikan masalah pencatatan penggunaan air PDAM. Di mana akan

digunakan Model YOLOv8 yang terdiri dari backbone seperti CSPDarknet atau MobileNet untuk ekstraksi fitur, neck seperti FPN atau PANet untuk menggabungkan fitur, dan head untuk prediksi akhir. Menggunakan desain tanpa anchor dan fungsi loss yang kompleks, model ini mendukung augmentasi data, transfer learning, pelatihan multi-skala, inferensi real-time dengan NMS, dan post-processing. Model ini juga dapat diterapkan di perangkat edge dan server cloud.

Kemudian data yang dihasilkan kemudian dikirim ke dalam rancangan arsitektur API. API ini merupakan jenis RESTful yang menggunakan metode GET dan POST untuk menerima serta mengirimkan data. Data hasil deteksi dapat dikirimkan ke website untuk ditampilkan atau disimpan di dalam database.

Desain sistem ini mencakup aspek perangkat lunak. Berikut adalah beberapa desain atau rancangan awal yang akan dibahas dalam desain sistem:

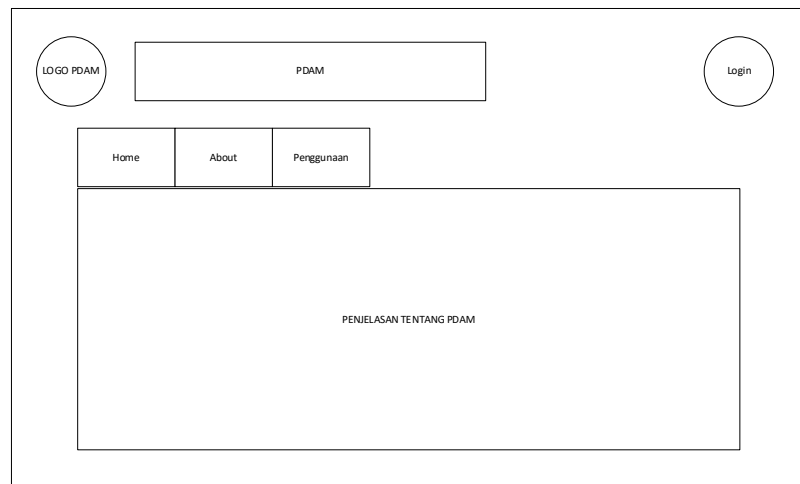
#### A. Desain Website

Dalam website yang dibuat akan terbagi menjadi 2 tampilan di mana untuk tampilan pertama yang dapat diakses oleh pengguna dan yang kedua hanya dapat diakses oleh karyawan PDAM

##### 1. Website pengguna

Untuk website pengguna akan terbuka untuk public dan dapat diakses untuk semua pengguna PDAM di mana terdapat halaman Home, About, dan juga tampilan table penggunaan meteran air analog yang dapat dilakukan filterin table berdasarkan tanggal penggunaan (Bulan), dan juga kisaran pembayaran dalam penggunaan air PDAM.





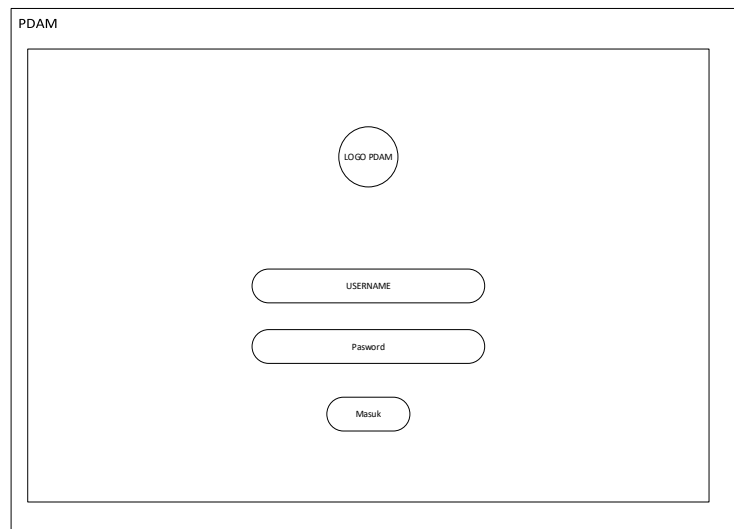
Gambar 3. 3 Tampilan WEB Penggunaan Air PDAM



Gambar 3. 4 Tampilan Data penggunaan air PDAM

## 2. Website Karyawan

Pada Website karyawan di mana akan ada akun bagi karyawan yang dapat digunakan untuk mengakses website penambahan data penggunaan air PDAM di mana Terdapat halaman home, about, table penggunaan, dan juga penambahan penggunaan air PDAM



PDAM

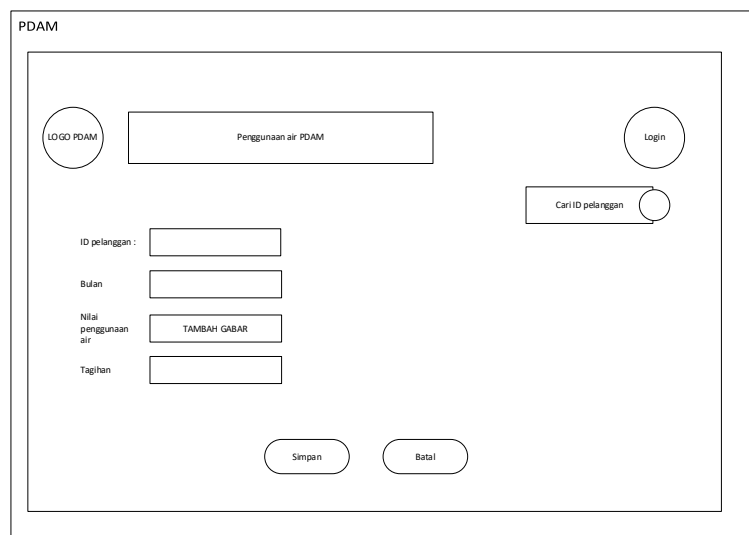
LOGO PDAM

USERNAME

Password

Masuk

Gambar 3. 5 tampilan login untuk Karyawan



PDAM

LOGO PDAM

Penggunaan air PDAM

Login

Cari ID pelanggan

ID pelanggan :

Bulan

Nilai penggunaan air

TAMBAH GABAR

Tagihan

Simpan

Batal

Gambar 3. 6 tampilan WEB penambahan data penggunaan air PDAM

## F. Teknik Pengujian

Pada tahap ini Pengujian dilakukan untuk mengetahui apakah Pengujian yang dilakukan untuk mengetahui apakah sistem yang dibangun telah berjalan dengan baik dan tepat, sesuai dengan fungsionalitas dan spesifikasi perangkat yang telah disediakan. Proses pengujian dibagi menjadi lima bagian, yakni pengujian model CNN, pengujian rotasi kamera, dan Pengujian website.

## 1. Pengujian model CNN

Sebelum dilakukan pengembangan system deteksi angka pada meteran analog mmaka dilakukan proses pengujian model. Pengujian model yang dilakukan dalam proses training model-model yang akan diuji terdiri dari model Resnet ,DenseNet MobileNet, EfficientNet, dan YOLOv8 dengan hyperparameter seperti Epoch, Image, Batch, Optimizer, dan runtime.

Tabel 3.1.Skenario Pengujian Model

Model	IMG	BATC H	OPTI MIZE R	EPOC H	Precisi on	Recall	Runti me
Resnet	404	26	adam	10	-	-	Detik menit jam
				50	-	-	Detik menit jam
DenseN et	404	26	adam	10	-	-	Detik menit jam
				50	-	-	Detik menit jam
Mobile Net	404	26	adam	10	-	-	Detik menit jam
				50	-	-	Detik menit jam
Efficien tNet	404	26	adam	10	-	-	Detik menit jam
				50	-	-	Detik menit jam
YOLO v8	404	26	adam	10	-	-	Detik menit jam
				50	-	-	Detik menit jam

## 2. pengujian Jumlah Epoch terhadap Kinerja Model

Tabel 4.4 pengujian terhadap Pengaruh Cahaya

waktu	Hitungan manual	Hasil deteksi	Akurasi (%)
pagi	-	-	0-100
siang	-	-	0-100
sore	-	-	0-100

### 3. Pengujian Transformasi Citra

Tabel 3.2 Pengujian Transformasi Citra

Transformasi	Hitungan manual	Hasil deteksi	Akurasi (%)
90°	Angka sebenarnya	Angka yang dideteksi system	0-100
180	Angka sebenarnya	Angka yang dideteksi system	0-100

### 4. Fungsionalitas Website

Pengujian implementasi sistem deteksi angka pada meteran air bertujuan untuk mengevaluasi akurasi model dalam mengenali angka dari gambar meteran analog. Proses ini menggunakan model CNN dan YOLOv8, dengan akurasi diukur dari perbandingan hasil deteksi dan angka sebenarnya. Hasil pengujian menunjukkan apakah angka berhasil "Terdeteksi" atau "Tidak Terdeteksi," mencerminkan efektivitas sistem dalam mengonversi informasi gambar menjadi data digital.

Tabel 3. 3 Skenario Fungsionalitas Website

Skenario pngujian	Kasus pengujian	Hasil yang diharapkan	Hasil Pengujian
Menyimpan Data ke Database	Data di simpan kedalam Database	System dapat menyimpan Database	Berhasil \ Tidak
Deteksi angka meteran	Gambar meteran analog	System dapat mendeteksi angka meteran analog	Terdeteksi \tidak
Menampilkan data ke website	Data hasil deteksi di tampilkan ke website	Data hasil deteksi tampilkan ke website	Berhasil \ Tidak

## G. Teknik Analisis Data

Penelitian ini akan menggunakan analisis kualitatif untuk mengevaluasi kinerja Algoritma YOLOv8, model-model CNN, API, dan website yang digunakan dalam mendukung pencatatan penggunaan air PDAM. Analisis kualitatif ini bertujuan untuk memberikan data statistik yang menunjukkan performa model-model CNN seperti ResNet, DenseNet, MobileNet, EfficientNet, dan YOLOv8 dalam mengonversi gambar menjadi data digital. Fokus utama analisis ini adalah membandingkan setiap model CNN dalam hal deteksi angka pada gambar meteran air analog.

Semua analisis ini diharapkan dapat memberikan wawasan penting mengenai keunggulan model-model CNN yang mampu menghasilkan akurasi yang tinggi dalam deteksi angka pada gambar meteran air analog. Data yang dihasilkan akan digunakan untuk mengevaluasi kinerja sistem dan membantu pengembangan sistem deteksi angka meteran air, yang pada akhirnya dapat menunjang sistem pencatatan penggunaan air PDAM serta membantu pengaturan biaya penggunaan air. Adapun tahap dalam analisis akurasi, diantaranya ialah

### 1. Analisis akurasi

Untuk analisis perbandingan model CNN seperti ResNet, DenseNet, MobileNet, EfficientNet, dan YOLOv8, kita akan mengevaluasi berdasarkan dua metrik utama: mAP (mean Average Precision) dan waktu komputasi.

mAP (mean Average Precision) adalah sebuah metrik umum yang digunakan untuk menilai tingkat ketepatan dalam mendeteksi suatu objek, dengan nilai berkisar antara 0 hingga 1. Semakin tinggi nilai mAP, semakin akurat sistem deteksi

objek dalam melakukan identifikasi. Dalam menghitung mAP diperlukan faktor-faktor seperti Intersection over Union (IOU), Precision, Recall, Precision Recall Curve, dan Average Precision (AP). Adapun persamaan untuk menghitung nilai mAP sebagaimana pada persamaan 3.1.

$$mAP = \frac{1}{n} \sum_{i=1}^n AP_i \quad (3.1)$$

Keterangan :

$n$  = Jumlah kelas atau objek yang dievaluasi

$AP_i$  = Average Precision untuk kelas atau objek ke- $i$

Persamaan di atas menghitung rata-rata Average Precision (AP) untuk setiap kelas, menggambarkan kinerja model dalam mengidentifikasi objek. mAP menunjukkan kinerja keseluruhan model. AP dihitung dengan menjumlahkan hasil kali selisih recall dan precision pada titik-titik recall yang berbeda. Adapun rumus untuk menghitung nilai Average Precision (AP) sebagaimana pada persamaan 3.2.

$$AP = \sum_n (Recall_n - Recall_{n-1}) \times precision(n) \quad (3.2)$$

Keterangan:

$n$  = indeks kelas

Average Precision (AP) dihitung dengan menjumlahkan hasil kali antara selisih recall pada dua titik berturut-turut dengan nilai precision pada titik recall tersebut. Ini memberikan estimasi luas area di bawah kurva precision-recall, yang kemudian dijumlahkan untuk memperoleh nilai AP, yaitu rata-rata precision pada

setiap titik recall. Rumus untuk menghitung precision dapat dilihat pada persamaan (3.3), yaitu:

$$\text{Precision} = \frac{TP}{TP+FP} \quad (3.3)$$

Sedangkan recall dihitung dengan rumus pada persamaan (3.5):

$$\text{Precision} = \frac{TP}{TP+FN} \quad (3.4)$$

Keterangan:

- TP = True Positive (nilai yang benar dan dihasilkan sistem benar)
- FP = False Positive (nilai yang salah tapi dihasilkan sistem benar)
- FN = False Negative (nilai yang salah dan dihasilkan sistem salah)

## 2. Analisis Fungsionalitas

Analisis fungsionalitas bertujuan untuk memastikan bahwa sistem yang dikembangkan beroperasi sesuai dengan tujuan yang telah ditetapkan. Proses ini memastikan bahwa sistem dapat menjalankan tugasnya dengan benar sesuai spesifikasi yang telah ditentukan sebelumnya. Evaluasi sistem dilakukan dengan fokus pada fungsionalitasnya, tanpa memperhatikan detail implementasi internal. Berbagai skenario pengujian dirancang untuk menguji berbagai aspek fungsional sistem, termasuk respons terhadap input yang berbeda dan pengujian dalam kondisi tertentu. Hasil dari setiap skenario diuji untuk menentukan apakah sistem berhasil memenuhi kebutuhan fungsional yang telah ditetapkan. Evaluasi dilakukan dengan menggunakan kriteria "Berhasil" atau "Tidak Berhasil" berdasarkan kemampuan sistem dalam memberikan respons yang sesuai dan memenuhi persyaratan fungsional yang telah ditentukan.

## BAB IV

### HASIL DAN PEMBAHASAN

#### A. Hasil penelitian

Penelitian ini diawali dengan pengumpulan *dataset* berupa gambar meteran air analog yang diambil secara langsung menggunakan ponsel dan kamera ESP32-CAM. Pengambilan gambar dilakukan pada pagi, siang, dan sore untuk menangkap variasi pencahayaan dan kondisi lingkungan. Objek utama yang difokuskan dalam *dataset* adalah angka pada meteran air analog yang menunjukkan nilai penggunaan air.

Setiap gambar mencakup *detail* angka meteran, bingkai meteran, serta elemen di sekitarnya sebagai konteks tambahan. Variasi kondisi meteran juga diperhatikan, termasuk meteran yang bersih, berdebu, atau terhalang oleh pantulan cahaya, sebagaimana ditunjukkan pada Gambar 4.1.



Pagi



Siang



Sore

Gambar 4. 1 Gambar Citra Meteran Air Analog

Pendekatan ini bertujuan untuk menghasilkan *dataset* yang representatif guna mendukung keakuratan deteksi dan pengolahan data. Variasi gambar yang dikumpulkan membantu model dalam mendeteksi angka pada meteran air, bahkan



dalam kondisi pencahayaan yang kurang optimal. Hal ini sangat penting karena variasi dalam kondisi gambar dapat meningkatkan kemampuan model untuk mengenali angka dengan lebih baik di berbagai situasi.

Dilakukan *augmentasi* data untuk memperkaya variasi Proses augmentasi ini mencakup rotasi gambar, *flipping horizontal*, dan penyesuaian warna. Dengan *augmentasi* ini, model diharapkan dapat membantu dalam mengenali angka pada meteran air dengan lebih baik. data *augmentasi* dapat dilihat pada gambar 4.2.

Preprocessing	Auto-Orient: Applied Resize: Stretch to 640x640
Augmentations	Outputs per training example: 3 Flip: Horizontal, Vertical Crop: 0% Minimum Zoom, 30% Maximum Zoom Rotation: Between -45° and +45° Grayscale: Apply to 15% of images Bounding Box: Flip: Horizontal

Gambar 4. 2 Augmentasi Citra

Hasil dari tahap *preprocessing* dan *augmentasi* adalah *dataset* yang terorganisir dengan baik, berkualitas tinggi, dan siap digunakan untuk melatih model deteksi angka. *Dataset* ini memungkinkan model untuk mengenali angka pada meteran air analog secara akurat, bahkan dalam kondisi yang kompleks atau bervariasi, sehingga mendukung kinerja model yang lebih baik dalam situasi nyata. Setelah proses *preprocessing* selesai, Data yang dikumpulkan terdiri dari 344 dataset yang kemudian di bagi menjadi 2 bagian yaitu 275 sebagai data pelatihan dan 69 sebagai data pengujian

Data yang telah dikumpulkan kemudian dilabeli menggunakan *bounding box* untuk menandai area angka pada meteran air. Proses pelabelan dilakukan secara manual menggunakan *platform* Roboflow, yang mempermudah pengaturan *bounding box* serta konversi data ke format yang mendukung pelatihan model, seperti XML (PASCAL VOC) atau JSON (COCO). Pemberian label berupa angka 0-9 memiliki peran yang sangat penting, karena label ini menjadi acuan bagi model dalam mendeteksi angka pada gambar meteran air dengan tepat dan akurat, seperti yang ditunjukkan pada Gambar 4.2.



Gambar 4. 3 Proses Pelabelan Citra

*Dataset* yang telah dilabel kemudian dibagi menjadi dua bagian, yaitu data pelatihan dan data pengujian. Sebanyak 80% dari *dataset* digunakan untuk pelatihan model, sementara 20% sisanya digunakan untuk pengujian. Pembagian ini bertujuan untuk mengukur kinerja model secara *objektif* dengan menguji kemampuan model pada data yang belum pernah dilihat sebelumnya, sehingga dapat diperoleh evaluasi yang lebih akurat tentang performa model.

## B. Pengujian sistem

### 1. Proses pelatihan dan pengujian model

#### a. Mengambil *Dataset*

Pada tahap ini, digunakan platform Roboflow untuk membantu mengelola dan mengambil dataset

```
!pip install roboflow

from roboflow import Roboflow
rf = Roboflow(api_key="MrTJ8S44S55knDjD0u0J")
project = rf.workspace("cassava-disease-classification").project("meteran-air-analog")
version = project.version(3)
dataset = version.download("yolov8")
```

#### b. Parameter pengujian

Pada tahap ini, ditetapkan lokasi penyimpanan dataset dan pengaturan parameter ukuran gambar *batch*, jumlah kelas dan juga model pelatihan *epoch* untuk mendapatkan hasil deteksi terbaik.

```
# Set parameters
label_directory_yolo = 'METERAN-AIR-ANALOG-7/train/labels'
image_directory_yolo = 'METERAN-AIR-ANALOG-7/train/images'
batch_size = 26
image_size = (640, 640)
num_classes = 10
num_epochs = 50
```

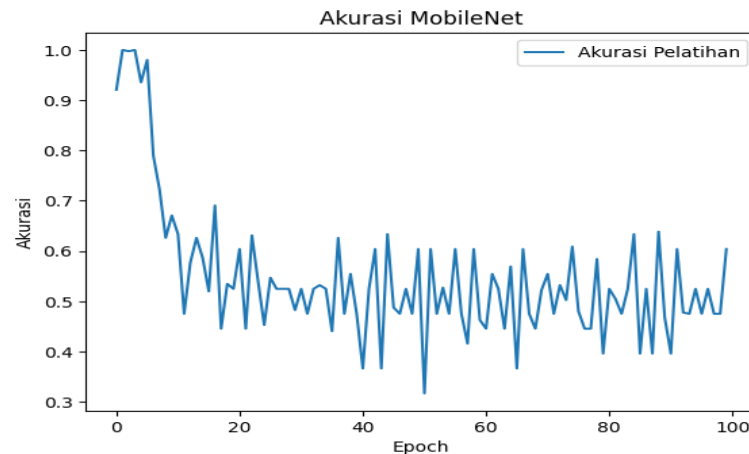
Dimana parameter yang digunakan untuk pelatihan untuk setiap model yaitu:

- Ukuran gambar : 640 x 640
- Batch size : 26
- Optimizer : adam

- Num\_classes : 10
- Num\_epoch : 50

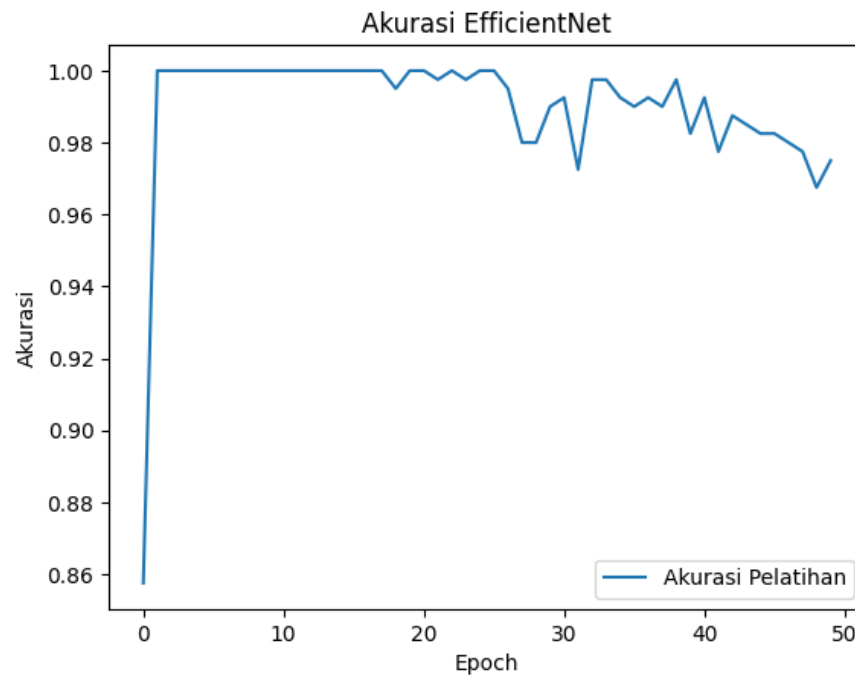
## 2. Pengujian Model

### a. Hasil perbandingan Plot accuracy



Gambar 4. 4 Plot Accuracy MobileNet

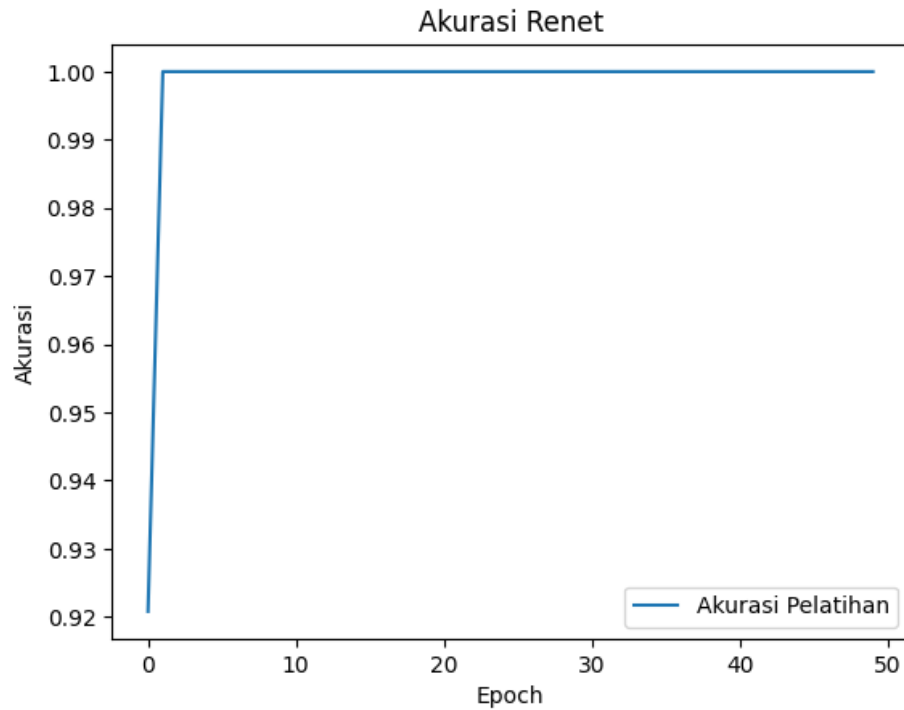
Hasil pengujian menggunakan model MobileNet menunjukkan bahwa pelatihan model menghasilkan akurasi yang kurang *optimal*, dengan rata-rata akurasi berada di sekitar 60%, sebagaimana ditunjukkan pada Gambar 4.4. Grafik tersebut menunjukkan bahwa akurasi awal model cukup tinggi, mendekati 100%. Namun, akurasi tersebut dengan cepat mengalami penurunan signifikan hingga berada pada kisaran 50–60%, diikuti oleh fluktuasi yang tidak konsisten sepanjang proses pelatihan. Selain itu, hasil pengujian precision dan recall tidak berhasil diperoleh, yang mengindikasikan bahwa model ini memiliki keterbatasan dalam menangani *dataset* yang digunakan.



Gambar 4. 5 Plot *Accuracy* EfficientNet

Hasil pengujian menggunakan model EfficientNet menunjukkan bahwa pelatihan model menghasilkan akurasi yang kurang optimal, dengan rata-rata akurasi berada di sekitar 60%, sebagaimana ditunjukkan pada Gambar 4.5. Grafik tersebut menunjukkan bahwa akurasi awal model cukup tinggi, mendekati 100%.

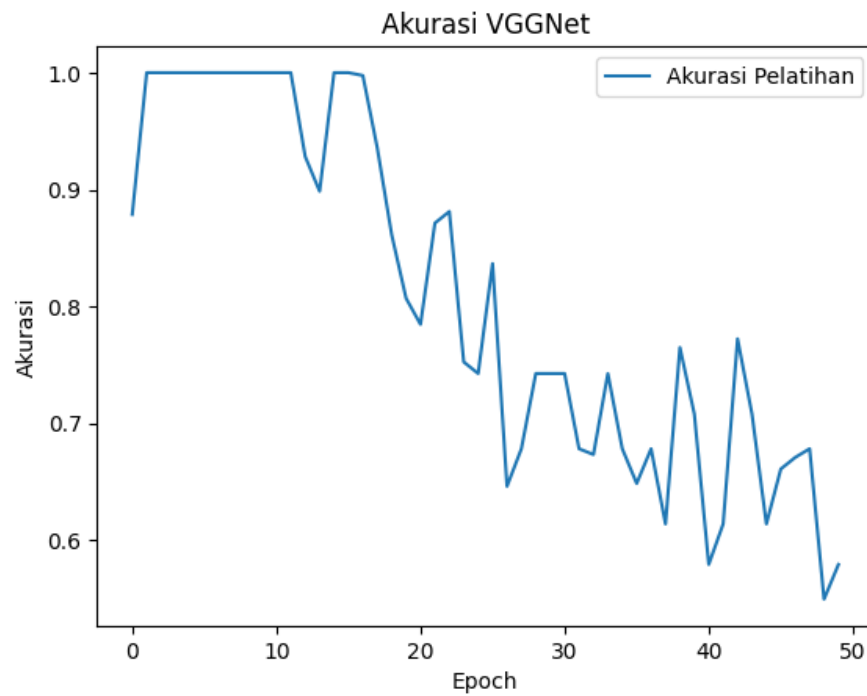
Namun, akurasi tersebut dengan cepat mengalami penurunan signifikan hingga berada pada kisaran 90–100%, diikuti oleh fluktuasi yang tidak konsisten sepanjang proses pelatihan. Selain itu, hasil pengujian precision dan recall tidak berhasil diperoleh, yang menunjukkan bahwa model ini memiliki keterbatasan dalam menangani *dataset* yang digunakan dan memerlukan optimasi lebih lanjut untuk meningkatkan performanya.



Gambar 4. 6 Plot *Accuracy* Resnet

Hasil akurasi ResNet menunjukkan bahwa pelatihan model mencapai tingkat akurasi yang optimal, dengan rata-rata akurasi mendekati 100%, seperti yang ditampilkan pada Gambar 4.6. Meskipun demikian, model memerlukan waktu komputasi yang cukup lama, yang menjadi salah satu kelemahan utama dalam implementasinya.

Meskipun akurat, ResNet memerlukan waktu komputasi tinggi, sehingga kurang cocok untuk sistem yang memerlukan respons cepat. Precision dan recall masing-masing sebesar 67%.



Gambar 4. 7 Plot Accuracy VGGNet

Hasil pengujian menggunakan model VGGNet menunjukkan bahwa pelatihan awal model mampu mencapai tingkat akurasi yang optimal. Namun, rata-rata akurasi mengalami penurunan yang signifikan hingga berada di bawah 60%, sebagaimana ditampilkan pada Gambar 4.7.

Selain itu, hasil evaluasi menunjukkan nilai precision dan recall yang sangat rendah, yaitu sebesar 0,02 atau 0%. Kekurangan ini mengindikasikan bahwa model VGGNet belum mampu menangani kompleksitas data pada *dataset* yang digunakan secara efektif.

Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size			
46/50	0G	1.111	0.7739	1.002	26	640: 100%	9/9 [02:45<00:00, 18.35s/it]		
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%	5/5 [01:05<00:00, 13.06s/it]	
	all	404	2628	0.894	0.838	0.93	0.636		
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size			
47/50	0G	1.128	0.7963	1.005	27	640: 100%	9/9 [02:48<00:00, 18.72s/it]		
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%	5/5 [01:05<00:00, 13.12s/it]	
	all	404	2628	0.893	0.846	0.934	0.64		
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size			
48/50	0G	1.1	0.7525	1.005	26	640: 100%	9/9 [02:45<00:00, 18.41s/it]		
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%	5/5 [01:05<00:00, 13.11s/it]	
	all	404	2628	0.884	0.839	0.934	0.642		
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size			
49/50	0G	1.113	0.782	1.016	26	640: 100%	9/9 [02:46<00:00, 18.45s/it]		
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%	5/5 [01:05<00:00, 13.03s/it]	
	all	404	2628	0.886	0.854	0.938	0.648		
Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size			
50/50	0G	1.099	0.7439	1.017	26	640: 100%	9/9 [02:44<00:00, 18.33s/it]		
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%	5/5 [01:05<00:00, 13.05s/it]	
	all	404	2628	0.889	0.858	0.939	0.649		

Gambar 4. 8 Hasil Training Model YOLOv8n

Hasil pengujian menggunakan model YOLOv8n menunjukkan bahwa pelatihan model mampu mencapai tingkat akurasi yang optimal, dengan nilai mAP50 sebesar 93% dan mAP50-95 sebesar 64%, sebagaimana ditampilkan pada Gambar 4.6. Selain itu, model ini menghasilkan nilai precision sebesar 88% dan *recall* sebesar 85%.

Model YOLOv8n juga memiliki waktu komputasi yang cukup cepat, menjadikannya sangat efisien untuk implementasi dalam sistem *real-time*. Hasil ini menunjukkan bahwa YOLOv8n memiliki keunggulan dalam mendeteksi *objek* dengan akurasi yang tinggi, memberikan prediksi yang akurat, serta memproses data dengan waktu yang singkat, sehingga cocok untuk mendukung kebutuhan sistem .



```

Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%| 13/13 [02:07<00:00, 9
all        404      2628      0.974      0.957      0.991      0.735

Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
49/50    0G        0.9686    0.4792    1.015     26         640: 100%| 26/26 [06:01<00:00, 13.92s/it]
Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%| 13/13 [02:19<00:00, 10
all        404      2628      0.971      0.961      0.991      0.742

Epoch  GPU_mem  box_loss  cls_loss  dfl_loss  Instances  Size
50/50    0G        0.9641    0.4686    1.013     26         640: 100%| 26/26 [06:12<00:00, 14.34s/it]
Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%| 13/13 [02:17<00:00, 10
all        404      2628      0.974      0.967      0.992      0.747

50 epochs completed in 6.849 hours.
Optimizer stripped from runs\detect\train11\weights\last.pt, 22.5MB
Optimizer stripped from runs\detect\train11\weights\best.pt, 22.5MB

Validating runs\detect\train11\weights\best.pt...
Ultralytics 8.3.86 Python-3.11.7 torch-2.6.0+cpu CPU (Intel Core(TM) i7-6700HQ 2.60GHz)
Model summary (fused): 72 layers, 11,129,454 parameters, 0 gradients, 28.5 GFLOPs
Class      Images  Instances  Box(P      R      mAP50  mAP50-95): 100%| 13/13 [02:08<00:00, 9
all        404      2628      0.974      0.967      0.992      0.747


Speed: 4.3ms preprocess, 302.5ms inference, 0.0ms loss, 0.7ms postprocess per image
Results saved to runs\detect\train11
Training complete!
Final training metrics:
Precision Akhir: 97.40%
Recall Akhir: 96.68%
ultralytics.utils.metrics.DetMetrics object with attributes:

```

Gambar 4. 9 hasil *Training* Model YOLOv8s

Hasil pengujian menggunakan model YOLOv8s menunjukkan bahwa pelatihan model mampu mencapai tingkat akurasi yang *optimal*, dengan nilai mAP50 sebesar 0,99 dan mAP50-95 sebesar 0,74, sebagaimana ditampilkan pada Gambar 4.7.

Selain itu, model ini menghasilkan nilai precision sebesar 97% dan *recall* sebesar 96%. Model YOLOv8s juga memiliki waktu komputasi yang cukup cepat, menjadikannya sangat efisien untuk implementasi dalam sistem real-time. Hasil ini menunjukkan bahwa YOLOv8 memiliki keunggulan dalam mendeteksi objek dengan akurasi yang tinggi,




Gambar 4. 10 Grafik Hasil Perbandingan Akurasi Model

Setelah melakukan pelatihan model CNN di dapatkan hasil akurasi YOLOv8s mencapai 99%, menjadikannya salah satu model terbaik setelah ResNet yang mencapai akurasi sempurna sebesar 100%. Jika dibandingkan dengan model lain seperti MobileNet 60,4%, VGGNet 66,75%, dan EfficientNet 97,5%, YOLOv8s unggul dalam hal akurasi dan efisiensi.

#### b. Hasil Perbandingan Model

Dari hasil akurasi dari setiap model kemudian dilakukan perbandingan berdasarkan precision, recall, Map50, mAP50-95 dan Runtime yang dapat dilihat pada gambar 4.11



Gambar 4. 11 Grafik Perbandingan Model

Dari gambar perbandingan model didapatkan hasil bahwa meskipun memiliki akurasi yang tinggi namun pada *precision* dan *recall* nya kurang maksimal dimana MobileNet dan efficienNet berada di 0% data pengujian dapat dilihat pada table 4.1

Tabel 4. 1 Perbandingan Model CNN

Model	Precision	Recall	mAP50	mAP50-95	Runtime
Resnet	67%	67%	85%	55%	521 menit
MobilNet	0 %	0 %	20%	5%	120 menit
VGGNet	2 %	2%	15%	4%	493 menit
EfficientNet	0 %	0%	25%	6%	422 menit
YOLOv8n	88 %	86 %	93%	64%	201 menit
YOLOv8s	97.40%	96.68%	99%	74%	302 menit


Berdasarkan Tabel 4.1, diperoleh hasil bahwa model yang paling sesuai untuk pengujian deteksi angka pada meteran air analog adalah model YOLOv8s yang menunjukkan performa terbaik dengan precision 97.4% ,recall sebesar 96.68%, serta waktu komputasi yang lebih cepat dibandingkan dengan model-model lainnya.

Keunggulan tersebut menunjukkan bahwa YOLOv8s tidak hanya mampu memberikan akurasi yang tinggi dalam mendeteksi angka pada meteran air analog, tetapi juga dapat memproses data dalam waktu yang *relatif* singkat, menjadikannya pilihan yang optimal untuk aplikasi *real-time*. Dengan

performa yang konsisten, YOLOv8s terbukti lebih unggul dalam hal kecepatan dan efisiensi dibandingkan dengan model lain yang diuji, seperti Resnet, MobileNet, dan EfficientNet. Hal ini menjadikan YOLOv8s lebih sesuai untuk implementasi dalam sistem deteksi otomatis pada meteran air analog yang membutuhkan akurasi tinggi dan waktu respons cepat.

Nilai pengujian model dari YOLOv8s dapat dilihat berdasarkan confusion Matrix Normalize, confusion Matrix dan Precision Recall Curve.

a. confusion Matrix Normalize




Gambar 4. 12 Grafik Confusion Matrix Normalize

Berdasarkan confusion matrix yang telah dinormalisasi, model menunjukkan performa yang sangat baik dalam mendeteksi angka 0–9, dengan sebagian besar nilai diagonal mendekati 1. Angka seperti 0, 1, 2, dan 7 memiliki akurasi hampir sempurna, menandakan model mampu mengenali bentuk angka dengan akurat.

Namun, terdapat kesalahan minor pada angka 5 dan 6 yang terkadang diklasifikasikan sebagai angka lain. Selain itu, kesalahan paling signifikan terjadi antara angka 9 dan kelas "background", di mana angka 9 sering dikira latar belakang dan sebaliknya. Hal ini menunjukkan perlunya peningkatan dalam membedakan angka dengan latar belakang.

Secara keseluruhan, model sudah bekerja dengan baik, tetapi masih perlu perbaikan terutama pada deteksi angka yang mirip atau menyatu dengan latar belakang.

#### b. confusion matrix



Gambar 4. 13 Grafik Confusion Matrix


Berdasarkan confusion matrix, model berhasil mengklasifikasikan angka 0–9 dan kelas background dengan cukup baik. Sebagian besar prediksi benar berada di diagonal utama, misalnya angka 0 dengan 953 prediksi benar, angka

2 dengan 225, dan angka 3 dengan 204. Hal ini menunjukkan model mampu mengenali angka-angka tersebut secara akurat.

Meskipun begitu, masih terdapat beberapa kesalahan klasifikasi, seperti angka 9 yang sering diklasifikasikan sebagai background (18 kasus) dan angka 8 (22 kasus). Selain itu, latar belakang juga beberapa kali dikira sebagai angka, khususnya angka 8 dan 9. Hal ini menunjukkan bahwa model masih kesulitan membedakan angka tertentu dari latar belakang.

Secara keseluruhan, model menunjukkan kinerja yang baik, namun perbaikan dibutuhkan untuk mengurangi kesalahan antara angka dan latar belakang, terutama pada angka yang bentuknya mirip atau kurang jelas dalam citra.

#### c. Precision Recall Curve



Gambar 4. 14 Grafik Precision Recall Curve

Berdasarkan grafik Precision-Recall, model menunjukkan performa yang sangat baik dalam mendeteksi setiap kelas angka dari 0 hingga 9. Semua kelas memiliki nilai presisi dan recall yang sangat tinggi, dengan mAP@0.5 keseluruhan mencapai 0.992. Ini menunjukkan bahwa model mampu mempertahankan keseimbangan antara presisi dan recall hampir mendekati sempurna.

Kelas dengan performa tertinggi ditunjukkan oleh angka 0 dan 5, masing-masing dengan nilai presisi sekitar 0.995. Sementara itu, angka dengan performa sedikit lebih rendah namun masih sangat baik adalah angka 1 dan 3 dengan nilai sekitar 0.989. Perbedaan ini sangat kecil dan tidak signifikan dalam konteks sistem klasifikasi yang stabil dan akurat.

Secara keseluruhan, grafik ini memperkuat temuan dari confusion matrix bahwa model yang digunakan memiliki kinerja sangat baik dan konsisten dalam mengenali angka, menjadikannya andal untuk diterapkan pada sistem pencatatan digital seperti deteksi angka meteran air.

### 3. Pengujian web

#### 1) Pembuatan web

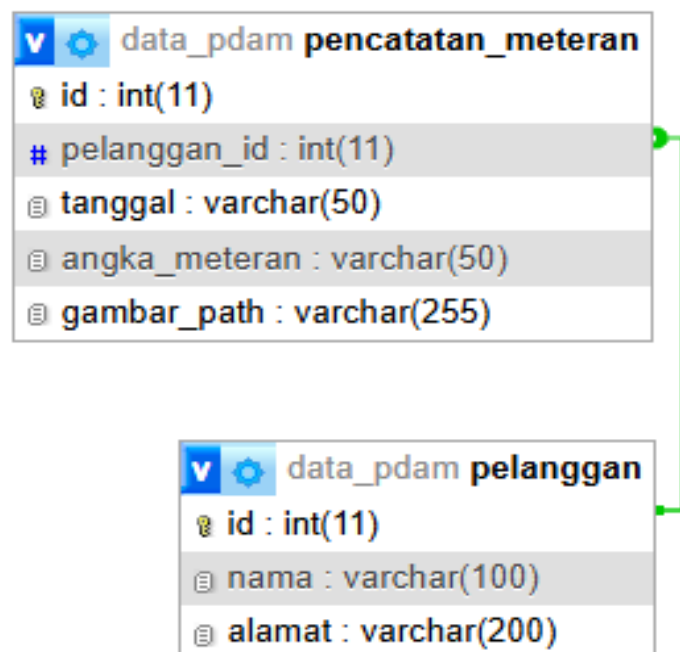
##### 1) Database

Database data\_pdam dikelola menggunakan Laragon untuk menyimpan informasi pelanggan dan hasil pencatatan angka meteran air secara otomatis, menggantikan pencatatan manual yang rentan terhadap kesalahan.

Informasi pelanggan disimpan dalam tabel pelanggan, yang terdiri dari kolom id sebagai *Primary Key*, serta nama dan alamat untuk mengidentifikasi pelanggan. Data ini memungkinkan pencatatan meteran dikaitkan langsung dengan pelanggan terkait.

Hasil deteksi angka meteran dicatat dalam tabel pencatatan\_meteran, yang memiliki kolom id sebagai identitas unik, pelanggan\_id sebagai *Foreign Key* ke tabel pelanggan, serta tanggal, angka\_meteran, dan gambar untuk menyimpan detail pencatatan.

Hubungan *one-to-many* antara tabel pelanggan dan pencatatan\_meteran memastikan setiap pelanggan dapat memiliki banyak riwayat pencatatan. Struktur ini memungkinkan sistem mengelola data secara efisien dan memastikan pemantauan penggunaan air lebih akurat. diagram database dapat dilihat pada gambar 4.12



Gambar 4. 15 Digram *Database*



## 2) Penggunaan flask

Flask digunakan dalam penelitian ini untuk membangun API yang menghubungkan sistem deteksi angka berbasis YOLOv8 dengan antarmuka pengguna. Flask dipilih karena sifatnya yang ringan, fleksibel, dan mudah diintegrasikan, sehingga memungkinkan pengolahan input gambar, pemanggilan model, serta pengiriman hasil prediksi dilakukan secara cepat dan efisien, dengan alur seperti gambar 4.13



Gambar 4. 16 Alur Penggunaan Flask

*Flask* digunakan sebagai backend untuk mengintegrasikan model deteksi angka ke dalam *website*. Pada alur kerjanya, *website* akan mengirimkan gambar meteran air melalui API yang dibangun menggunakan *Flask*. Setelah gambar diterima oleh API, gambar tersebut diproses menggunakan model CNN yang telah dikembangkan untuk mendeteksi angka-angka pada meteran. Hasil dari proses deteksi ini berupa data teks yang merepresentasikan angka meteran. Data teks tersebut kemudian dikirimkan kembali ke *website* untuk ditampilkan kepada pengguna. Selain itu, hasil deteksi juga disimpan secara otomatis ke dalam database untuk keperluan pencatatan dan pengelolaan data penggunaan air secara digital. Integrasi ini memungkinkan proses

pencatatan angka meteran air menjadi lebih cepat, akurat, dan efisien dibandingkan metode manual.

### 3) Tampilan *website*

Tampilan *website* pencatatan angka meteran PDAM dirancang untuk mempermudah pengguna dalam mencatat dan mendeteksi angka meteran secara otomatis. Bagian atas halaman menampilkan formulir input yang memungkinkan pengguna memasukkan nama pelanggan, alamat, tanggal pencatatan, serta mengunggah gambar meteran untuk diproses menggunakan metode CNN dan OCR. Setelah dikirim, sistem akan mendeteksi angka meteran dan menampilkan hasilnya dalam tabel pencatatan.

Tabel ini menyajikan data pelanggan, alamat, tanggal pencatatan, dan angka meteran yang telah terdeteksi, serta dilengkapi dengan fitur pencarian untuk mempermudah akses informasi. Selain itu, *website* ini menyediakan tombol Export ke CSV dan Export ke PDF yang memungkinkan pengguna mengunduh data dalam format yang lebih mudah digunakan untuk dokumentasi dan pelaporan.

Dengan desain yang sederhana namun fungsional, *website* ini bertujuan untuk meningkatkan efisiensi pencatatan angka meteran air secara digital, mendukung transparansi, dan mengurangi kesalahan pencatatan manual. Tampilan *website* dapat dilihat pada gambar 4.14



**PENCATATAAN ANGKA METERAN PDAM**

**Tambah Data & Deteksi Angka Meteran**

Nama Pelanggan:

Alamat:

Tanggal:

Upload Gambar Meteran:  No file chosen

**Kirim & Deteksi**

**Data Hasil Pencatatan**

Cari data...

No	Nama	Alamat	Tanggal	Angka Meteran
1	herianto	GRIYA KENARI C7	2025-03-12	9990310
2	herianto	GRIYA KENARI C7	2025-03-13	9990310
3	Iskandar	GRIYA KENARI C4	2025-03-12	947572
4	Iskandar	GRIYA KENARI C4	2025-03-14	40
5	Iskandar	GRIYA KENARI C4	2025-03-13	349441
6	rijal	GRIYA KENARI C4	2025-03-14	941512

**Export ke CSV**

**Export ke PDF**

Gambar 4. 17 Tampilan website

## 3) Pengujian website





Tabel 4. 2 Skenario Fungsionalitas Website



Skenario pngujian	Kasus pengujian	Hasil yang diharapkan	Hasil Pengujian
Menyimpan Data ke Database	Data di simpan kedalam Database	System dapat menyimpan Database	Berhasil
Deteksi angka meteran	Gambar meteran analog	System dapat mendeteksi angka meteran analog	Terdeteksi
Menampilkan data ke website	Data hasil deteksi di tampilkan ke website	Data hasil deteksi tampilkan ke website	Berhasil

Semua pengujian berhasil dilakukan dengan baik, dalam menyimpan data deteksi angka , menampilkan data dan pencarian data. Hasil pengujian dapat dilihat pada table 4.2

## 4. Hasil pengujian perbandingan transformasi

Tabel 4. 3 Pengujian Transformasi

Gambar	Hitungan manual	Deteksi	Hasil Deteksi	keterangan
	0486599		3500017 9	Angka belum sempurna mendeteksi, masih ada dan belum berurutan
	8956840		8956840	Terdeteksi sempurna
	0486599		0019887 96	Hasil deteksi masih kurang untuk gambar





	0486599		0486599	Terdeteksi sempurna
---	---------	--	---------	---------------------

Hasil pengujian menunjukkan bahwa pada gambar dengan transformasi posisi angka secara vertikal, sistem masih mampu mendeteksi angka, namun sering terjadi kesalahan dalam pengenalan angka dan urutannya belum akurat. Sebaliknya, pada gambar dengan posisi angka horizontal, deteksi berjalan dengan sangat baik, di mana angka-angka berhasil dikenali secara tepat dan sesuai urutan. Temuan ini menunjukkan bahwa orientasi angka dalam gambar sangat memengaruhi performa sistem deteksi, sehingga perlu dilakukan peningkatan pada model atau teknik preprocessing untuk menangani variasi orientasi dengan lebih efektif. perbandingan

#### 5. hasil pengujian terhadap Pengaruh Cahaya

*Tabel 4. 4 pengujian terhadap Pengaruh Cahaya*

waktu	citra	Hitungan manual	Hasil Gambar	Hasil deteksi	keterangan
pagi		0489884		048988 4	Terdeteksi sempurna

siang		0490867		049588 7	Angka 0 terdeteksi menjadi 5 dan angka 6 menjadi 8
sore		0490391		049039 1	Terdeteksi sempurna

Hasil pengujian menunjukkan bahwa sistem masih mengalami kesalahan dalam mendeteksi angka. Beberapa angka terbaca salah angka 0 menjadi 5, dan angka 6 menjadi 8. Kesalahan ini bisa terjadi karena pencahayaan yang kurang baik, posisi angka yang miring, atau gangguan seperti bayangan dan pantulan cahaya.

Selain itu, ada juga kasus di mana angka menjadi ganda atau tidak terbaca dengan jelas. Hal ini bisa disebabkan oleh angka yang terlalu berdekatan atau model yang belum bisa membedakan batas antar angka dengan baik.

Untuk memperbaiki deteksi angka, bisa dilakukan beberapa langkah seperti memastikan pencahayaan yang cukup saat mengambil gambar, menghilangkan gangguan pada gambar, dan melatih ulang model dengan lebih banyak contoh angka dalam berbagai kondisi.

## **BAB V**

### **Kesimpulan**

#### **A. Kesimpulan**

Berdasarkan hasil penelitian, sistem deteksi angka pada meteran air analog menggunakan metode CNN menunjukkan potensi yang baik dalam mengonversi angka menjadi data digital. Model YOLOv8 terbukti memiliki akurasi tertinggi dibandingkan dengan model lainnya, dengan nilai precision sebesar 97,40% dan recall sebesar 96,68%. Namun, masih terdapat beberapa kendala dalam deteksi angka, terutama pada pembacaan angka sesuai urutan atau dalam posisi vertikal yang tidak beraturan.

Pencahayaan juga berpengaruh signifikan terhadap hasil deteksi, di mana kondisi pencahayaan yang kurang optimal menyebabkan kesalahan dalam membaca angka. Implementasi sistem ini ke dalam website juga telah dilakukan, memungkinkan pencatatan penggunaan air PDAM secara otomatis dan real-time.

#### **B. Saran**

Untuk meningkatkan akurasi sistem deteksi angka pada meteran air analog, beberapa hal yang dapat dilakukan ke depannya antara lain:

1. Peningkatan *Dataset*

Menambah variasi gambar berdasarkan sudut pengambilan, pencahayaan, dan kondisi lingkungan untuk meningkatkan ketahanan model terhadap berbagai situasi.

## 2. Optimasi Model

Melakukan fine-tuning pada model CNN agar lebih responsif terhadap variasi posisi dan kondisi angka pada meteran.

## 3. Integrasi dengan IoT

Mengembangkan sistem agar terhubung dengan perangkat IoT sehingga pencatatan angka dapat dilakukan otomatis tanpa intervensi manual.

Dengan perbaikan tersebut, diharapkan sistem deteksi dapat bekerja lebih akurat dan efisien dalam mendukung pencatatan penggunaan air PDAM.



## DAFTAR PUSTAKA

- Aini, R., Gunawan, I., Studi, P., Informatika, T., & Hamzanwadi, U. (2023). *Website Monitoring Penggunaan Air PDAM ( e - Water ) Berbasis Internet of Things*. 1(2).
- Azizah, N. (2024). *Metode Pengumpulan Data Debit Air Pada Saluran Distribusi Air PDAM Makassar Berbasis IoT*.
- Dan, L., & Luas, P. (2020). *Implementasi algoritma CNN untuk klasifikasi citra lahan dan perhitungan luas*. 1(1), 166–174.
- Deteksi, U., Produk, O., & Perusahaan, D. I. (2024). *Inti nusa mandiri*. 18(2), 107–114.
- Giri, E. P. (2021). *Convolutional Neural Network Konsep , Penerapan , Dan Implementasi Staf Pengajar : Departemen Ilmu Komputer FMIPA IPB*.
- Hermawan, I. (2015). *Rancang Bangun Sistem Pendeteksi dan Pengenalan Angka Pada Meteran Air PDAM Menggunakan Metode Template Matching Correlation Indra Hermawan*. 1, 55–61.
- KAPARANG, A. I. (2024). *Pengembangan Layanan Application Programming Interface Konversi Citra Meteran Air Analog Ke Teks Berbasis Web*.
- Lauwis, D. (2017). *Alat Penghitung Debit Air dan Biaya Pemakaian Air dari Flowmeter PDAM yang Dapat Dipantau Melalui Internet*. September.
- Lestari, R. I., Ramadhani, R., Toni, A., & Candra, R. (2021). *Air dan Dampak Kelangkaannya Bagi Perekonomian Masyarakat Urban : Studi Pustaka Pulau Jawa*. 6(1).
- Lubis, I. W. C. (2021). *Pengimplementasian ocr menggunakan cnn untuk ekstraksi teks pada gambar*. vol.9(<https://journal.untar.ac.id/index.php/jiksi/issue/view/495>). <https://doi.org/https://doi.org/10.24912/jiksi.v10i1.17836>
- Minarno, A. E., Akbi, D. R., Munarko, Y., & Malang, U. M. (2022). *Workshop machine learning klasifikasi tumor otak pada citra mri menggunakan convolutional neural network dan support vector machine*. 6(1), 107–117.
- OJJA, A. R. B. (2024). *Pengembangan Sistem Data Center Data Capture Meteran Air Analog*

*Berbasis ESP32CAM.*

Parawangi, A., Malik, I., Negara, I. A., Makassar, U. M., Negara, I. A., Makassar, U. M., Negara, I. A., & Makassar, U. M. (2021). *Pengaruh kualitas pelayanan terhadap kepuasan konsumen perusahaan daerah air minum ( pdam ) di.* 2(April).

Pramono, S., Yuliantoro, P., & Pamungkas, S. R. (2022). *Sistem Monitoring Tekanan Pada Pipa Air Menggunakan Arduino Uno Pada Jaringan Lora 920-923 Mhz.* 6, 473–483. <https://doi.org/10.30865/mib.v6i1.3448>

Rachmaniar, A., Diana, D., Saefudin, M., & Parulian, R. (2022). *Application Of Computer Vision Detection Of Apples And Oranges Using Python Language.* 6(2), 455–466. <https://doi.org/10.52362/jisicom.v6i2.946>

Rahmawan, F., Informatika, J. T., Indonesia, B., Habibi, R., Informatika, J. T., Internasional, B., Setyawan, M. Y. H., & Informatika, J. T. (2023). *Rekognisi Huruf Tulisan Tangan Menggunakan Convolutional Neural Network.* 6(3), 262–276.

Riyadi, A. S., Wardhani, I. P., Wulandari, M. S., & Widayati, S. (2022). *Perbandingan Metode ResNet , YoloV3 , dan TinyYoloV3 pada Deteksi Citra dengan Pemrograman Python.* 15(1), 135–144.

Studi, P., Elektro, T., Petra, U. K., & No, J. S. (2022). *Sistem Pemantauan Meteran Air Berbasis Optical Character.* 15(2), 73–78.

*Water meter: definisi, fungsi, jenis dan spesifikasinya.* (2024). <https://arita.co.id/water-meter-definisi-fungsi-jenis-dan-spesifikasinya>

Windihastuty, W. (2023). *Deteksi Angka Meter Air Dengan Membandingkan Algoritma.* 27(1), 103–111. <https://doi.org/10.46984/sebatik.v27i1.2294>